

SARGE：面向中文金融文档级事件抽取的 Schema-Aware Role-Grounded Extractor

2026 年 5 月 20 日

1 摘要

中文金融文档级事件抽取需要在长文本中聚合跨句证据，同时区分同一文档内的多条同类事件记录，并把每个角色槽位绑定到可评测的文本取值。本文提出 SARGE (Schema-Aware Role-Grounded Extractor)，将事件 schema、角色槽位约束与候选表面片段组织为受控结构化生成过程，由 Qwen3-4B-Instruct-2507 及 LoRA 适配器直接生成 JSON 事件记录，再进入固定槽位评测。本文只报告已有完整证据的结果：ChFinAnn-Doc2EDAG full-dev 3204 篇文档，以及 DuEE-Fin labeled test 1171 篇文档。以 legacy_doc2edag_native_fixed_slot 为主表口径，SARGE 在 ChFinAnn 上取得 85.49 F1，在 DuEE-Fin labeled test 上取得 77.96 F1。与 EPAL、SEELE 的公开 fixed-slot 表格相比，SARGE 在 ChFinAnn 上达到 85.5 F1，在 DuEE-Fin 上高于 EPAL Table 1 的 76.4 F1，但低于 SEELE Table 3 的 80.8 F1。本文不声称多种子均值、统计显著性、隐藏测试集结果或线上 leaderboard 结论，而是把当前可追溯实验证据组织为一个可编译、可核验的中文论文草稿。

2 方法论

2.1 任务定义

给定中文金融文档 x 与事件 schema 集合 S ，文档级事件抽取的目标是输出事件记录集合 $\hat{\mathcal{E}}$ 。每条记录包含一个事件类型以及若干角色-文本取值对。金融文档中常见的困难并非只来自单个实体的识别，而是来自跨句证据、多事件共现以及同一角色在多个事件中的重复取值。SARGE 因此不把系统设计为“先自由生成、再事后修补”的流程，而是把输出空间提前收缩到 schema 已定义的事件类型、角色槽位和文档中可见的候选片段之内。

2.2 Schema-aware role-grounded generation

SARGE 的核心过程如图 1 所示。系统首先读取文档文本和数据集 schema，并将事件类型与角色列表渲染为稳定的 schema-slot contract。随后，surface memory 从文档中组织候选表面片段，使生成器在回答每个角色槽位时优先绑定到可追溯文本证据。生成阶段使用 Qwen3-4B-Instruct-2507 与 LoRA 适配器，采用确定性解码，并通过 role-safe JSON 合约约束输出结构。最后，record disambiguation 对同文同类多记录进行整理，避免把多个相近事件误合并为单条记录。




图 1: SARGE 方法流程。方法以 schema-slot contract 与 surface memory 约束结构化生成, 并在输出后区分 fixed-slot 主表、unified strict 诊断与 official-style 专用轨道。

这一设计的重点是把大模型能力放在结构化决策上, 而不是让模型自由改写事件定义。schema 提供事件类型和角色边界, surface memory 提供候选证据, JSON 合约提供可解析输出格式。三者共同约束生成空间, 使结果能够直接转换为 canonical JSONL, 并进入与历史文档级事件抽取工作相兼容的 fixed-slot 评测。

2.3 评测口径

本文主表只使用 legacy_doc2edag_native_fixed_slot。该指标在同一文档、同一事件类型内进行事件记录匹配, 并在固定 schema 角色槽位上统计 TP、FP 与 FN。精确率、召回率和 F1 定义为

$$P = \frac{TP}{TP + FP}, \quad R = \frac{TP}{TP + FN}, \quad F1 = \frac{2PR}{P + R}.$$

该口径用于与 EPAL Table 1、SEELE Table 2/3 等公开 fixed-slot 表格对齐。内部 unified_strict 指标回答的是 canonical JSONL 严格文本匹配问题, docfee_official 只服务于 DocFEE official-style 轨道, 二者不与本文主表指标混算。

3 创新点

3.1 Schema-slot 受控生成

SARGE 将事件 schema 显式写入生成约束, 使模型在每个事件类型下只能围绕已定义角色槽位组织答案。相比自由文本生成, 这种方式减少了角色名漂移、遗漏槽位和额外虚构字段的风险, 也使预测结果可以稳定进入 fixed-slot 评测器。

3.2 Surface-memory 候选约束

文档级金融事件通常包含大量公司名、日期、比例和金额, 单纯依靠语言模型记忆容易混淆相邻数值。SARGE 将文档中的候选表面片段作为 surface memory 输入模型, 使角色填充更接近“从文档证据中选择并组织”的过程。该约束并不声称解决所有数值推理问题, 但能为后续错误定位提供可追溯的候选边界。

3.3 Role-safe JSON 合约

SARGE 的输出不是开放式自然语言，而是 role-safe JSON 事件记录。固定的 JSON 合约要求模型显式给出事件类型与角色参数，并避免把解释性文本混入预测字段。这个设计使解析失败、空预测、非法事件类型和非法角色能够被单独诊断，而不是在评测阶段被隐式吞掉。

3.4 记录消歧与指标边界

同一篇金融文档可能描述多条同类事件，例如多次质押、减持或股份回购。SARGE 在输出后保留记录级边界，并对同类多记录做显式消歧。与此同时，本文把 fixed-slot 主表、unified strict 诊断和 official-style 专用轨道分开报告，避免把回答不同问题的指标压成一个不可解释的综合数。

3.5 可追溯实验证据

本文的数值都绑定到具体 run root、manifest hash 和 eval hash。ChFinAnn 主结果来自 full-dev 3204 文档完成运行，DuEE-Fin 主结果来自 labeled test 1171 文档完成运行。DuEE-Fin-dev500 500 文档结果只作为开发诊断补充，不提升为主表性能。这样的证据组织方式使论文草稿可以在不重新训练、不重新推理的前提下被审计。

4 实验

4.1 数据集、基线与运行配置

本文使用两个中文金融文档级事件抽取数据集。ChFinAnn-Doc2EDAG 保留 3204 篇 full-dev 文档作为本轮报告的 ChFinAnn 结果来源；DuEE-Fin 使用 labeled test 1171 篇文档作为主结果来源。公开基线采用 EPAL 文档中的 Table 1、Appendix Table 4/5，以及 SEELE 文档中的 Table 2/3。对于公开表格未报告的 P/R 或单事件、多事件细分，本文保留缺失值，不做插补。

表 1: SARGE 主结果运行配置

数据集	split	文档数	后端	模型	权重形态	解码	seed	F1
ChFinAnn full-dev	dev	3204	vLLM 0.8.5	Qwen3-4B + LoRA ep2 merged	BF16 merged weights	k=1 greedy; temperature=None; top_p=1.0	13	85.5
DuEE-Fin labeled test	test	1171	HF Transformers 5.4.0	Qwen3-4B + LoRA ep2 adapter	4-bit NF4, double quant, bf16	k=1 greedy; temperature=None; top_p=1.0	13	78.0

ChFinAnn 完成运行使用 vLLM 0.8.5 与 BF16 merged weights，模型为 Qwen3-4B-Instruct-2507 加 LoRA ep2 merged 权重，seed 为 13，采用 $k = 1$ greedy 解码。DuEE-Fin labeled test 完成运行使用 HF Transformers 5.4.0、4-bit NF4 与 LoRA ep2 adapter，seed 同为 13，采用相同的确定性解码设置。两个主结果均来自服务器 ‘/data/TJK/DEE/SARGE/’ 下的完成运行，而不是本地 GPU 推理。

4.2 主结果

表 2 给出公开 fixed-slot 口径下的总体结果。SARGE 在 ChFinAnn full-dev 上取得 85.5 F1，高于 EPAL Table 1 的 83.4，也略高于 SEELE Table 2 的 85.1。DuEE-Fin labeled test 上，SARGE 取得 78.0 F1，高于 EPAL Table 1 的 76.4，但低于 SEELE Table 3 的 80.8。这个结论应被理解为当前公开表格口径下的有限比较，而不是隐藏测试集或线上 leaderboard 结论。

表 2: 公开基线与 SARGE 主结果 (单位: %)

数据集	方法	来源	P	R	F1	F1(S.)	F1(M.)
ChFinAnn	Doc2EDAG	EPAL Table 1	82.7	75.2	78.8	83.9	67.3
ChFinAnn	DE-PPN	EPAL Table 1	83.7	76.4	79.9	85.9	68.4
ChFinAnn	PTPCG	EPAL Table 1	83.7	75.4	79.4	88.2	—
ChFinAnn	GIT	EPAL Table 1	82.3	78.4	80.3	87.6	72.3
ChFinAnn	ReDEE	EPAL Table 1	83.9	79.9	81.9	88.7	74.1
ChFinAnn	ProCNet	EPAL Table 1	83.6	78.1	80.8	87.5	73.5
ChFinAnn	EPAL	EPAL Table 1	83.1	83.5	83.4	89.7	76.6
ChFinAnn	SEELE	SEELE Table 2	—	—	85.1	—	—
ChFinAnn	SARGE	本项目 ChFinAnn full-dev	83.5	87.6	85.5	88.3	83.1
DuEE-Fin	Doc2EDAG	EPAL Table 1	67.1	60.1	63.4	69.1	58.7
DuEE-Fin	DE-PPN	EPAL Table 1	69.0	33.5	45.1	54.2	21.8
DuEE-Fin	PTPCG	EPAL Table 1	71.0	61.7	66.0	—	—
DuEE-Fin	GIT	EPAL Table 1	69.8	65.9	67.8	73.7	63.8
DuEE-Fin	ReDEE	EPAL Table 1	77.0	72.0	74.4	78.9	70.6
DuEE-Fin	ProCNet	EPAL Table 1	79.3	71.4	75.1	80.1	71.0
DuEE-Fin	EPAL	EPAL Table 1	77.3	75.5	76.4	81.2	72.7
DuEE-Fin	SEELE	SEELE Table 3	—	—	80.8	—	—
DuEE-Fin	SARGE	本项目 labeled test	76.6	79.3	78.0	79.3	77.5




图 2: 公开 fixed-slot 基线与 SARGE 主结果对比。SARGE 的 DuEE-Fin 数值来自 labeled test 1171 文档, 不使用 DuEE-Fin-dev500 500 文档开发诊断结果。

从数据集差异看，ChFinAnn 的 schema 边界和角色集合相对更稳定，surface memory 与 schema-slot contract 更容易把候选证据压缩进可控空间。DuEE-Fin 的角色集合更大，同类事件和数值参数更密集，因此 SARGE 虽然超过 EPAL 公开表格，但整体仍低于 SEELE 的公开结果。

4.3 分事件类型分析

表 3: ChFinAnn 分事件类型 fixed-slot F1 (单位：%)

代码	事件类型	EPAL	SEELE	SARGE	SARGE-EPAL	SARGE-SEELE
EF	EquityFreeze	74.8	78.8	87.3	12.5	8.5
ER	EquityRepurchase	93.4	92.0	90.3	-3.1	-1.7
EU	EquityUnderweight	76.3	77.7	82.5	6.2	4.8
EO	EquityOverweight	77.3	82.4	84.6	7.3	2.2
EP	EquityPledge	81.5	83.1	84.6	3.1	1.5

表 4: DuEE-Fin labeled test 分事件类型 fixed-slot F1 (单位：%)

代码	事件类型	EPAL	SEELE	SARGE	SARGE-EPAL	SARGE-SEELE
CL	公司上市	59.1	66.5	64.1	5.0	-2.4
SR	股东减持	74.5	76.7	76.7	2.2	0.0
EO	股东增持	57.5	75.5	71.5	14.0	-4.0
EA	企业收购	68.3	72.1	72.2	3.9	0.1
FI	企业融资	76.1	79.1	77.6	1.5	-1.5
ER	股份回购	91.3	94.8	91.0	-0.3	-3.8
EP	质押	78.2	85.3	79.5	1.3	-5.8
CP	解除质押	76.8	84.8	79.2	2.4	-5.6
GB	企业破产	69.3	62.0	67.4	-1.9	5.4
EL	亏损	86.1	86.2	83.9	-2.2	-2.3
BG	被约谈	71.1	58.0	70.3	-0.8	12.3
BI	中标	76.3	76.6	76.9	0.6	0.3
SC	高管变动	61.2	64.8	63.4	2.2	-1.4

表 3 显示，SARGE 在 ChFinAnn 的 EquityFreeze、EquityUnderweight、EquityOverweight 和 EquityPledge 上均超过 EPAL 与 SEELE，EquityRepurchase 则低于 SEELE 但仍保持 90.3 F1。该结果与方法设计相符：当事件 schema 边界清楚、角色取值在文本中显式出现时，surface memory 与 role-safe contract 能够有效降低生成空间。

表 4 显示，DuEE-Fin 的分类型结果更不均衡。SARGE 在企业收购、企业破产、股东增持、股东减持、股份回购、解除质押、质押和中标等类别上达到或接近 EPAL/SEELE 的公开结果，但在若干类别上仍低于 SEELE。该现象提示 DuEE-Fin 的难点不仅在 schema 约束，还包括更复杂的角色组合、数值密集证据和同文多事件消歧。




图 3: ChFinAnn 与 DuEE-Fin labeled test 分事件类型 F1 对比。图中只比较公开表格中的 EPAL、SEELE 与本项目 SARGE fixed-slot 结果。

表 5: 评测指标族边界

指标族	本文位置	边界说明
legacy_doc2edag_native_fixed_slot	主表	与 EPAL/SEELE 公开 fixed-slot 表格对齐；报告 ChFinAnn full-dev 与 DuEE-Fin labeled test。
unified_strict	内部诊断/附录候选	回答跨数据集 canonical JSONL 的严格文本匹配问题；不与论文 fixed-slot 主表混算。
docfee_official	不用于本文主表	仅适用于 DocFEE official-style 轨道；本文两个主数据集不报告该指标。

4.4 指标族边界与限制

本文的实验部分有意保持窄口径。主结果不报告统计显著性，因为当前证据不是多种子重复实验；不报告 $\text{mean} \pm \text{std}$ ，因为 seed 17/19 尚未作为同口径主实验补齐；不报告 LRD test 结论，因为当前主表选择的是 W9 no-LRD labeled test 完成运行；不报告线上 leaderboard 或隐藏测试集结论，因为仓库没有对应完整证据。上述限制并不削弱当前结果的可复核性，反而界定了它们能够支持的论文表述范围：SARGE 已经在两个中文金融文档级事件抽取数据集上形成可追溯 fixed-slot 结果，其中 ChFinAnn 达到 85.5 F1，DuEE-Fin labeled test 达到 78.0 F1。