

SARGE：面向中文金融文档级事件抽取的 Schema-Aware Role-Grounded Extractor

2026 年 5 月 20 日 (draft_v2)

1 摘要

中文金融文档级事件抽取需要在长文本中聚合跨句证据、区分同一文档内的多条同类事件记录,并把每个角色槽位绑定到可评测的文本取值。本文提出 SARGE(Schema-Aware Role-Grounded Extractor),把事件 schema、角色槽位约束与文档候选表面片段组织为受控结构化生成过程:由 Qwen3-4B-Instruct-2507 加 LoRA 适配器在 role-safe JSON 合约下直接生成事件记录,经规则化记录消歧后进入固定槽位评测。本文严格只报告已有完整证据的结果:ChFinAnn-Doc2EDAG *dev* (full-dev, 3204 篇) legacy fixed-slot F1 为 85.5, DuEE-Fin 内部 *labeled test* (1171 篇) 为 78.0。需要特别说明:上述两数与 EPAL/SEELE 论文公开表格(其在各自 *test split* 上报告)放在同一表格仅作**公开表格参考点**,而非同测试集 head-to-head; ChFinAnn 与 DuEE-Fin 的主结果分别来自 vLLM BF16 与 HF 4-bit NF4 两个推理后端(详见 §4)。本文进一步用**已完成的真实运行**给出四类分析:监督微调增益、推理后端对比、解码策略与输出鲁棒性,其中 SARGE 在两数据集上 schema-valid 率为 1.0、零解析失败, DuEE-Fin *labeled test* 的 exact-record F1 (42.8) 明显高于 ProcNet 同口径参考 (22.7)。本文不声称多种子均值、统计显著性、隐藏测试集/线上 leaderboard 结论或 learned 记录消歧 (LRD) 的 *test* 结论,而是把当前可追溯实验证据组织为一个可编译、可核验的中文论文草稿。

2 相关工作

文档级事件抽取。 ChFinAnn 与 Doc2EDAG 确立了中文金融 DEE 的实体-角色填表范式;其后 GIT、DE-PPN、PTPCG、ReDEE、ProCNet 等在图结构、集合预测、剪枝路径与关系增强方向上推进; EPAL 与 SEELE 进一步在跨记录建模与事件结构上取得更强的 fixed-slot 结果。DuEE-Fin 则提供了角色集合更大、同文多事件更密集的中文金融基准。这些工作大多基于专用编码器 + 结构化解码,本文在相同的 fixed-slot 评测口径下,转而以受控 LLM 生成实现端到端抽取。

基于 LLM 的信息抽取与受限解码。 将抽取重写为生成任务(如 schema 引导生成、function calling)以及在解码阶段施加语法/JSON 约束(grammar-constrained decoding、xgrammar/outlines 等)已较为常见。SARGE 与之的区别不在“用 schema 约束 JSON”本身,而在于面向**中文金融文档级、多记录的完整链路**:把规则候选作为 surface memory 绑定角色取值、用 anchor 角色对同类多记录做保守消歧、并以严格分离的指标族报告,使生成式系统能与既有 fixed-slot 表格对齐。

中文金融事件抽取。 中文金融文本数值密集（金额、比例、股数、日期）且实体相邻易混，单纯依赖语言模型记忆容易在相邻数值间出错。SARGE 用规则候选提供可追溯的候选边界，把角色填充变为”从文档证据中选择并组织”，为错误定位提供锚点。

3 方法

SARGE 的整体流程如图 1 所示，由六个阶段组成。下文按真实实现逐一说明。




图 1: SARGE: schema-aware role-grounded generation pipeline. 文档与 schema 经 surface memory 与 role-safe JSON 合约约束受控生成，解析与规则记录消歧后输出 canonical JSONL，并区分 legacy fixed-slot 主表、unified_strict 诊断与 official-style 专用轨道。

3.1 任务定义

给定中文金融文档 x 与事件 schema 集合 S ，其中每个事件类型 t 关联一个有序角色集合 $\mathcal{R}_t$ 。文档级事件抽取的目标是输出事件记录集合 $\hat{\mathcal{E}} = \{(t_i, \{(r, v_r)\}_{r \in \mathcal{R}_{t_i}})\}$ ，每条记录给出事件类型与若干”角色—文本取值”对。评测在固定 schema 角色槽位上、同文档同事件类型内进行记录匹配 (§3.7)。SARGE 的核心约束是： t_i 必须取自 S ，角色必须取自 $\mathcal{R}_{t_i}$ ，取值优先绑定到文档中可见的候选片段。

3.2 Surface memory：规则候选片段

surface memory 从文档逐段文本用一组确定性正则规则抽取候选表面片段，覆盖中文金融文档的高频取值类型：公司名片段、金额、比例、阿拉伯/中文日期、股份数量、带职务/敬称的人名、引号实体与股票代码（实现见 surface_memory/builder.py）。每个候选记录其表面串、上下文窗口、来源规则与初步角色分数。生成前按优先级（金额/日期/股数优先）排序并去重，截取至多 40 个候选喂入提示。该机制不声称解决全部数值推理，但为后续角色填充与错误定位提供可追溯的候选边界。

3.3 Prompt 与 role-safe JSON 合约

提示按六段拼装：[Dataset]、[Schema]、[Document]、[Surface Candidates]、[Event Slot Plan]、[Instruction]（见 generation/prompt.py）。schema 渲染为”事件类型 → 角色列表”逐行文本，并要求模型将角色名从 schema 原样复制，不翻译、不别名、不折叠。输出契约固定为 canonical 形式（见 data/canonical.py）：

```
{"doc_id": "...",
  "events": [
    {"event_type": "质押",
      "arguments": {
        "质押方": [{"text": "公司A"}],
        "事件时间": [{"text": "2023-06-01"}],
        "质押股票/股份数量": [{"text": "1000万股"}]}}
```

事件键严格为 {event_type, arguments}，每个角色取值严格为 {text} 列表。该契约把”解释性文本混入字段”排除在外，使非法事件类型、非法角色、空预测、解析失败可被**单独诊断**而非在评测阶段被隐式吞掉。

3.4 受控生成

生成阶段使用 Qwen3-4B-Instruct-2507 加 LoRA 适配器。推理以 response_prefix 为 {"events": 引导，主结果采用 $k = 1$ 确定性 greedy 解码 (do_sample=False)。系统另支持 schema-aware constrained decoding (SACD, 经 vLLM 的 xgrammar guided decoding 将输出约束为按事件类型 oneOf 的 JSON schema)，本文将其作为可选诊断而非主结果配置（实现见 scripts/infer_checkpoint.py、scripts/infer_checkpoint_vllm.py、generation/schema_decoding.py）。

3.5 解析与诊断

解析器 (generation/parser.py) 先做 JSON 抽取（剥离 markdown 围栏、移除前后多余文本），再逐事件校验：事件类型是否属于 $\mathcal{S}$ 、角色是否属于 $\mathcal{R}_t$ 、取值形状是否合法，并分别累计 parse_failure、invalid_event_type、invalid_role 等诊断计数。这些计数在 §4 中作为输出鲁棒性证据报告。

3.6 规则记录消歧（主路径，no-LRD）

同类多记录的消歧使用**规则 planner** (postprocess/rule_planner.py)，也是本文主结果所用路径。每个目标事件类型预定义一组 *anchor* 角色 (ANCHOR_ROLES_BY_EVENT_TYPE，例如”质押”的 anchor 为质押方/质押物/质押股份数量/事件时间)。planner 依次执行：精确去重、空目标事件丢弃、多 anchor 值的保守拆分、anchor 与 arguments 兼容时的保守合并、以及同 anchor 签名下的近重复保留更完整记录。其要点是**只有 anchor 签名相同且角色兼容的记录才允许合并**，避免把高相似但互斥的真实记录误并为一条。

本文亦实现了一个 learned 记录消歧 (LRD) 原型 (postprocess/lrd_planner.py, 含 safe-anchor 修复, 使学习到的 cluster 在合并时继承 anchor/role 兼容边界)。但 LRD 仅作为诊断与未来工作; **本文主表与全部对比均为 no-LRD 规则路径**, 不报告 LRD 的 test 结论。

3.7 Canonical JSONL 与三轨评测口径

预测导出为 canonical JSONL (evaluation/export.py), 再转评测器格式 (evaluation/evaluator_adapter.py) 后由 scripts/eval_three_tracks.py 跑三轨。主表只用 legacy_doc2edag_native_fixed_slot: 在同文档、同事件类型内匹配记录, 并在固定 schema 角色槽位上统计 TP 、 FP 、 FN ,

$$P = \frac{TP}{TP + FP}, \quad R = \frac{TP}{TP + FN}, \quad F1 = \frac{2PR}{P + R}.$$

该口径用于与 EPAL/SEELE 公开 fixed-slot 表格对齐。指标族边界见表 1: unified_strict 回答 canonical JSONL 的严格文本匹配 (并提供 exact-record 诊断), docfee_official 仅服务 DocFEE official-style 轨道, 二者均不与主表混算。

表 1: 评测指标族边界。三族回答不同问题, 不可压成单一综合数。

指标族	本文位置	边界说明
legacy_doc2edag_native_fixed_slot	主表	与 EPAL/SEELE 公开 fixed-slot 表格对齐; 报告 ChFinAnn full-dev 与 DuEE-Fin labeled test。
unified_strict	附录诊断	回答 canonical JSONL 的严格文本匹配问题, 并提供 exact-record 诊断; 不与 fixed-slot 主表混算。
docfee_official	不用于本文主表	仅适用于 DocFEE official-style 轨道; 本文两个主数据集不报告该指标。

4 实验

4.1 数据集、基线与运行配置

本文使用两个中文金融文档级事件抽取数据集。ChFinAnn-Doc2EDAG 取其 dev (full-dev, 3204 篇) 作为本轮 ChFinAnn 结果来源; DuEE-Fin 使用内部构造的 labeled test (1171 篇) 作为主结果来源。¹ 公开基线采用 EPAL 论文 Table 1 / Appendix Table 4-5 与 SEELE 论文 Table 2-3 的报告值; 对原文未报告的 P/R 或单/多事件细分保留缺失值, 不做插补。

可比性声明 (重要)。 EPAL/SEELE 的公开数字是在其各自 test split 上报告的, 而 SARGE 在 ChFinAnn 为 dev、在 DuEE-Fin 为内部 labeled test。因此本文所有“高于/低于”均应理解为公开表格口径下的参考点比较, 而非同一隐藏测试集或线上 leaderboard 上的 head-to-head。运行配置见表 2: 两个数据集的主结果分别来自 vLLM BF16 merged 与 HF 4-bit NF4 + LoRA 两

¹服务器内部数据集目录名为 DuEE-Fin-dev500, 其中 dev500 是数据集构造标签, 与文档数无关; 该 labeled test split 含 1171 篇文档。

个后端——这是因为 full-dev 上只完成了 vLLM 整集 run、DuEE labeled test 上只完成了 HF 整集 run（后端差异本身在 §4.4 量化）。两结果均来自服务器 /data/TJK/DEE/SARGE/ 的完成运行，seed 13。

表 2: SARGE 主结果运行配置。两个数据集使用不同推理后端：ChFinAnn 用 vLLM BF16 merged (full-dev 上唯一已完成的整集 run)，DuEE-Fin 用 HF 4-bit NF4 + LoRA (dev 上较 vLLM 高约 3.9pp，见消融)。

数据集	split	文档数	后端	模型	权重	解码	seed	F1
ChFinAnn	dev (full-dev)	3204	vLLM 0.8.5	Qwen3-4B + LoRA ep2 merged	BF16 merged	k=1 greedy	13	85.5
DuEE-Fin	labeled test	1171	HF Transformers 5.4.0	Qwen3-4B + LoRA ep2 adapter	4-bit NF4 + bf16 compute	k=1 greedy	13	78.0

4.2 主结果

表 3: 公开 fixed-slot 基线与 SARGE 主结果 (单位: %)。EPAL/SEELE 取自其论文 *test* split 公开表格；SARGE 在 ChFinAnn 为 *dev*(full-dev 3204)、DuEE-Fin 为内部 *labeled test*(1171)。split 口径不同，对比仅作公开表格参考点，非同测试集 head-to-head。

数据集	方法	来源/split	P	R	F1	F1(S.)	F1(M.)
ChFinAnn	Doc2EDAG	EPAL Table 1	82.7	75.2	78.8	83.9	67.3
ChFinAnn	DE-PPN	EPAL Table 1	83.7	76.4	79.9	85.9	68.4
ChFinAnn	PTPCG	EPAL Table 1	83.7	75.4	79.4	88.2	—
ChFinAnn	GIT	EPAL Table 1	82.3	78.4	80.3	87.6	72.3
ChFinAnn	ReDEE	EPAL Table 1	83.9	79.9	81.9	88.7	74.1
ChFinAnn	ProCNet	EPAL Table 1	83.6	78.1	80.8	87.5	73.5
ChFinAnn	EPAL	EPAL Table 1	83.1	83.5	83.4	89.7	76.6
ChFinAnn	SEELE	SEELE Table 2	—	—	85.1	—	—
ChFinAnn	SARGE	本项目 (dev/full-dev)	83.5	87.6	85.5	88.3	83.1
DuEE-Fin	Doc2EDAG	EPAL Table 1	67.1	60.1	63.4	69.1	58.7
DuEE-Fin	DE-PPN	EPAL Table 1	69.0	33.5	45.1	54.2	21.8
DuEE-Fin	PTPCG	EPAL Table 1	71.0	61.7	66.0	—	—
DuEE-Fin	GIT	EPAL Table 1	69.8	65.9	67.8	73.7	63.8
DuEE-Fin	ReDEE	EPAL Table 1	77.0	72.0	74.4	78.9	70.6
DuEE-Fin	ProCNet	EPAL Table 1	79.3	71.4	75.1	80.1	71.0
DuEE-Fin	EPAL	EPAL Table 1	77.3	75.5	76.4	81.2	72.7
DuEE-Fin	SEELE	SEELE Table 3	—	—	80.8	—	—
DuEE-Fin	SARGE	本项目 (labeled test)	76.6	79.3	78.0	79.3	77.5

表 3 给出公开 fixed-slot 口径下的总体结果。在公开表格参考点意义上，SARGE 在 ChFinAnn full-dev 上取得 85.5 F1，高于 EPAL Table 1 的 83.4，与 SEELE Table 2 的 85.1 同量级并略高；在 DuEE-Fin labeled test 上取得 78.0 F1，高于 EPAL Table 1 的 76.4，但低于 SEELE Table 3 的 80.8。再次强调：由于 split 口径不一致，这不是隐藏测试集或 leaderboard 结论。

从数据集差异看，ChFinAnn 的 schema 边界与角色集合相对稳定，surface memory 与 role-




图 2: SARGE 与公开 fixed-slot 基线主结果 (坐标轴自 0 起, 不截断)。SARGE 的 ChFinAnn 为 dev(full-dev)、DuEE-Fin 为 labeled test, 与基线 test split 口径不同, 对比仅作参考。

safe 合约更易把候选证据压进可控空间; DuEE-Fin 角色集合更大、同类事件与数值参数更密集, 因此 SARGE 虽超过 EPAL 公开表格, 但整体仍低于 SEELE。

4.3 分事件类型分析

表 4: ChFinAnn 分事件类型 fixed-slot F1 (dev/full-dev, 单位: %)

代码	事件类型	EPAL	SEELE	SARGE	Δ EPAL	Δ SEELE
EF	EquityFreeze	74.8	78.8	87.3	12.5	8.5
ER	EquityRepurchase	93.4	92.0	90.3	-3.1	-1.7
EU	EquityUnderweight	76.3	77.7	82.5	6.2	4.8
EO	EquityOverweight	77.3	82.4	84.6	7.3	2.2
EP	EquityPledge	81.5	83.1	84.6	3.1	1.5

表 4 显示, SARGE 在 ChFinAnn 的 EquityFreeze、EquityUnderweight、EquityOverweight、EquityPledge 上均超过 EPAL 与 SEELE 的公开值; EquityRepurchase 为 90.3, 低于 EPAL (93.4) 与 SEELE (92.0) 但仍处高位。该结果与方法设计相符: 当 schema 边界清楚、角色取值在文本中显式出现时, surface memory 与 role-safe 合约能有效降低生成空间。

表 5 显示 DuEE-Fin 分类型结果更不均衡: SARGE 在企业收购、企业破产、股东减持、股份回购、解除质押、质押、被约谈、中标等类别上达到或接近 EPAL/SEELE 的公开值, 但在公司上市、股东增持、质押、解除质押等类别上仍低于 SEELE。这提示 DuEE-Fin 的难点不仅在 schema 约束, 更在复杂角色组合、数值密集证据与同文多事件消歧。

表 5: DuEE-Fin labeled test 分事件类型 fixed-slot F1 (单位: %)

代码	事件类型	EPAL	SEELE	SARGE	Δ EPAL	Δ SEELE
CL	公司上市	59.1	66.5	64.1	5.0	-2.4
SR	股东减持	74.5	76.7	76.7	2.2	0.0
EO	股东增持	57.5	75.5	71.5	14.0	-4.0
EA	企业收购	68.3	72.1	72.2	3.9	0.1
FI	企业融资	76.1	79.1	77.6	1.5	-1.5
ER	股份回购	91.3	94.8	91.0	-0.3	-3.8
EP	质押	78.2	85.3	79.5	1.3	-5.8
CP	解除质押	76.8	84.8	79.2	2.4	-5.6
GB	企业破产	69.3	62.0	67.4	-1.9	5.4
EL	亏损	86.1	86.2	83.9	-2.2	-2.3
BG	被约谈	71.1	58.0	70.3	-0.8	12.3
BI	中标	76.3	76.6	76.9	0.6	0.3
SC	高管变动	61.2	64.8	63.4	2.2	-1.4




图 3: ChFinAnn (dev) 与 DuEE-Fin (labeled test) 分事件类型 fixed-slot F1 对比, 仅比较 EPAL、SEELE 与本项目 SARGE。

4.4 消融与分析

本节全部基于已完成的真实运行（来自 docs/exp_result.md 与服务器 eval），不引入任何新训练或推理。

监督微调增益。 表 6 与图 4 给出 no-SFT 基座与 LoRA-SFT 在同 split、同后端下的对比。ChFinAnn (vLLM, full-dev) 由 18.6 提升到 85.5 (+66.9pp)；DuEE-Fin (dev500) 在 HF 后端由 3.8 提升到 76.7 (+72.8pp)、在 vLLM 后端由 11.2 提升到 72.8 (+61.5pp)。这说明任务的难度主要由领域适配承担，受控生成框架在微调后才能稳定落到 fixed-slot 评测。

表 6: 监督微调 (SFT) 增益。同一 split、同一后端下，no-SFT 基座与 LoRA-SFT 的 fixed-slot F1 对比 (单位: %)。

数据集	split	后端	no-SFT	SFT	Δ
ChFinAnn-Doc2EDAG	dev (full-dev, 3204)	vLLM 0.8.5 BF16	18.6	85.5	66.9
DuEE-Fin-dev500	dev (500)	HF Transformers 4-bit NF4 + LoRA	3.8	76.7	72.8
DuEE-Fin-dev500	dev (500)	vLLM 0.8.5 BF16 merged	11.2	72.8	61.5




图 4: 监督微调增益 (同 split / 同后端)。

推理后端。 表 7 在同 split、同 $k = 1$ greedy 下对比 HF 4-bit NF4 + LoRA 与 vLLM BF16 merged。DuEE-Fin (dev500) 上 HF 明显优于 vLLM (76.7 vs 72.8, -3.9pp)，ChFinAnn (dev500) 上二者接近 (84.4 vs 84.2, -0.3pp)。该系统性差异 (已验证非 balanced_json_stopping 截断所致) 正是主结果按数据集选择不同后端的原因，并应作为局限如实记录 (§4.5)。

解码策略。 表 8 与图 5 (右) 显示， $k = 4$ 采样在两数据集上整体不优于 $k = 1$ greedy：ChFinAnn full-dev 上 $T=0.7$ 较 greedy 下降 1.2pp；DuEE-Fin dev500 上仅 $T=0.3$ 略高 (73.9 vs 72.8)， $T=0.5/0.7$ 均不及 greedy。主结果因此采用确定性 greedy。

表 7: 推理后端对比 (同 split、同 k=1 greedy)。HF 4-bit NF4 + LoRA 与 vLLM BF16 merged 的 fixed-slot F1 (单位: %)。

数据集	split	HF 4-bit NF4	vLLM BF16	Δ
DuEE-Fin-dev500	dev (500)	76.7	72.8	-3.9
ChFinAnn-Doc2EDAG	dev (500)	84.4	84.2	-0.2

表 8: 解码策略消融 (vLLM BF16)。greedy(k=1) 与 sampling(k=4, top_p=0.95) 在不同温度下的 fixed-slot F1 (单位: %)。

数据集	split	k=1 greedy	k=4 T=0.3	k=4 T=0.5	k=4 T=0.7
DuEE-Fin-dev500	dev (500)	72.8	73.9	72.7	72.3
ChFinAnn-Doc2EDAG	dev (full-dev, 3204)	85.5	—	—	84.3




图 5: 左: 推理后端对比 (同 split, k=1 greedy); 右: 解码策略消融 (vLLM BF16)。

输出鲁棒性与 exact-record。 表 9 显示 role-safe 合约的直接收益：ChFinAnn dev 与 DuEE-Fin test 上 schema-valid 率均为 1.0，解析失败、非法事件类型、非法角色计数均为 0。在 unified_strict 口径下，DuEE-Fin labeled test 的 exact-record F1 为 42.8，明显高于 ProcNet 同口径 seed42 参考的 22.7。该对比衡量的是**整条记录**的严格正确率，是 fixed-slot 之外对多记录消歧质量的补充证据。

表 9: 输出鲁棒性与 exact-record 诊断 (unified_strict 口径)。schema-valid rate 为 schema 合法预测占比；exact-record F1 = $2 \cdot \text{record_exact_match} / \text{validated_record}$ 。ProcNet 为同口径 seed42 参考。

指标	ChFinAnn dev	DuEE-Fin test
schema-valid rate	1.0	1.0
parse failures	0.0	0.0
invalid event types	0.0	0.0
invalid roles	0.0	0.0
SARGE exact-record F1	–	42.9
ProcNet exact-record F1 (seed42)	–	22.7

4.5 限制

本文有意保持窄口径：

- **split 可比性：**ChFinAnn 主结果在 dev、DuEE-Fin 在内部 labeled test，与 EPAL/SEELE 的 test split 不同；与公开表格的比较仅为参考点。
- **后端不对称：**两数据集主结果用了不同推理后端(full-dev 仅有 vLLM 整集 run、DuEE labeled test 仅有 HF 整集 run)；ChFinAnn full-dev 的 HF 同后端 cross-check 与 DuEE test 的 vLLM 对照尚未完成。
- **单种子：**仅 seed 13，不报告 mean±std 与统计显著性。
- **记录消歧：**主结果为 no-LRD 规则路径；learned LRD 仅诊断，不报告 test 结论。
- **无隐藏测试集/leaderboard 结论：**仓库无对应完整证据。

这些限制界定了当前证据能支持的表述范围，但不削弱其可复核性：所有数值均绑定到 run root、eval 哈希与本地快照，并由资产生成脚本的完整性断言锁定，防止编辑漂移。

5 结论

本文提出 SARGE，一个面向中文金融文档级事件抽取的 schema-aware role-grounded LLM 管线：以规则候选作 surface memory、以 role-safe JSON 合约约束受控生成、以 anchor 规则消歧处理同类多记录，并以严格分离的指标族报告。在公开 fixed-slot 表格参考点意义上，SARGE 在 ChFinAnn full-dev 取得 85.5 F1、在 DuEE-Fin labeled test 取得 78.0 F1，并在两数据集上实

现 1.0 的 schema-valid 率与零解析失败。后续工作包括补齐同后端 cross-check 与多种子结果、以及完成 learned 记录消歧的 test 评测。