

SARGE：面向中文金融文档级事件抽取的 Schema-Aware Role-Grounded Extractor

2026 年 5 月 20 日 (draft_v2)

1 摘要

中文金融文档级事件抽取需要在长文本中聚合跨句证据、区分同一文档内的多条同类事件记录，并把角色槽位绑定到可评测的文本取值。本文提出 SARGE (Schema-Aware Role-Grounded Extractor)，将事件 schema、角色槽位约束与文档候选表面片段组织为受控结构化生成过程：Qwen3-4B-Instruct-2507 经 LoRA 适配后在 role-safe JSON 合约下生成事件记录，再经规则化记录消歧进入固定槽位评测。当前可追溯实验显示，SARGE 在 ChFinAnn-Doc2EDAG *dev* (full-dev, 3204 篇) 上的 Legacy-FS F1 为 85.5，在 DuEE-Fin *labeled test* (1171 篇) 上的 Legacy-FS F1 为 78.0。由于 SARGE 与 EPAL/SEELE 公开表格采用的 split 与推理后端设置并不完全一致，上述比较仅作为公开表格参考点。进一步分析显示，监督微调带来主要增益；在输出层面，SARGE 在两个数据集上均达到 1.0 的 schema-valid 率与零解析失败，DuEE-Fin *labeled test* 的 exact-record F1 为 42.9，高于 ProcNet 同口径参考 (22.7)。这些结果表明，surface memory 与 role-safe JSON 合约能够为中文金融多记录抽取提供稳定的结构化输出边界，同时当前结论仍受单种子、split 与后端不对称等因素限制。

2 相关工作

文档级事件抽取。 ChFinAnn 与 Doc2EDAG 确立了中文金融 DEE 的实体—角色填表范式，核心问题是在同文档、同事件类型下完成固定 schema 槽位的记录匹配。GIT、DE-PPN、PTPCG、ReDEE、ProcNet 等工作进一步从图结构、集合预测、剪枝路径与关系增强等方向改进 fixed-slot 抽取。EPAL 与 SEELE 则更强调跨记录结构建模，在公开表格中提供了更强的 fixed-slot 参考点。本文沿用这一可比较的 fixed-slot 输出空间，但将抽取过程改写为受控 LLM 结构化生成。

结构建模与生成式抽取。 DuEE-Fin 提供了角色集合更大、同文多事件更密集的中文金融基准，使记录边界与数值角色选择成为主要难点。另一方面，将抽取重写为生成任务（如 schema 引导生成、function calling）以及在解码阶段施加语法/JSON 约束（grammar-constrained decoding、xgrammar/outlines 等）已较为常见。SARGE 与这些思路的区别不在于单独使用 schema 约束 JSON，而在于面向中文金融文档级、多记录的完整链路：把规则候选作为 surface memory 绑定角色取值、用 anchor 角色对同类多记录做保守消歧，并以严格分离的指标族报告，使生成式系统能够与既有 fixed-slot 表格对齐。

中文金融事件抽取。 中文金融文本数值密集（金额、比例、股数、日期）且实体相邻易混，单纯依赖语言模型内部记忆容易在相邻数值间出错。SARGE 用规则候选提供可追溯的候选边界，把角色填充转化为“从文档证据中选择并组织”，为错误定位提供锚点。

3 方法

SARGE 的整体流程如图 1 所示，由证据接地、role-safe 生成、解析规范化三个主模块与三类评测轨道组成。下文按真实实现逐一说明。




图 1: SARGE 的 schema-aware role-grounded generation pipeline。输入文档与 schema 经过 surface memory、role-safe JSON 合约约束生成、解析与规则记录消歧后，导出 canonical JSONL，并进入 Legacy-FS 主表、Unified-Strict 诊断与 DocFEE-Official 专用轨道。

3.1 任务定义

给定中文金融文档 x 与事件 schema 集合 S ，其中每个事件类型 t 关联一个有序角色集合 $\mathcal{R}_t$ 。文档级事件抽取的目标是输出事件记录集合

$$\hat{\mathcal{E}} = \left\{ \left(t_i, \{ (r, v_r) \}_{r \in \mathcal{R}_{t_i}} \right) \right\}_{i=1}^n.$$

每条记录给出事件类型与若干“角色—文本取值”对。评测在固定 schema 角色槽位上、同文档同事件类型内进行记录匹配 (§3.7)。SARGE 的核心约束是：事件类型 t_i 必须来自 S ，角色 r 必须来自对应角色集合 $\mathcal{R}_{t_i}$ ，取值 v_r 优先绑定到文档中可见的候选片段。

3.2 Surface memory：规则候选片段

surface memory 从文档逐段文本用一组确定性正则规则抽取候选表面片段，覆盖中文金融文档的高频取值类型：公司名片段、金额、比例、阿拉伯/中文日期、股份数量、带职务/敬称的人名、引号实体与股票代码（实现见 `surface_memory/builder.py`）。每个候选记录其表面串、上下文窗口、来源规则与初步角色分数。生成前按优先级（金额/日期/股数优先）排序并去重，截取至多

40 个候选输入至提示。该机制并未试图完全解决数值推理问题，而是为后续角色填充与错误定位提供可追溯的候选边界。

3.3 Prompt 与 role-safe JSON 合约

提示按六段拼装：[Dataset]、[Schema]、[Document]、[Surface Candidates]、[Event Slot Plan]、[Instruction]（见 generation/prompt.py）。schema 渲染为”事件类型 → 角色列表”逐行文本，并要求模型将角色名从 schema 原样复制，不翻译、不别名、不折叠。输出契约固定为 canonical 形式（见 data/canonical.py）：

```
{"doc_id": "...",
  "events": [
    {"event_type": "质押",
      "arguments": {
        "质押方": [{"text": "公司A"}],
        "事件时间": [{"text": "2023-06-01"}],
        "质押股票/股份数量": [{"text": "1000万股"}]}}
```

事件键严格为 {event_type, arguments}，每个角色取值严格为 {text} 列表。该契约把“解释性文本混入字段”排除在外，使非法事件类型、非法角色、空预测、解析失败可被**单独诊断**，而不是在评测阶段被隐式忽略。

3.4 受控生成

生成阶段使用 Qwen3-4B-Instruct-2507 加 LoRA 适配器。推理以 response_prefix 为 {"events": 引导，主结果采用 $k = 1$ 确定性 greedy 解码（do_sample=False）。系统另支持 schema-aware constrained decoding (SACD)，可通过 vLLM 的 xgrammar 引导式解码将输出约束为按事件类型 oneOf 的 JSON schema；但本文主结果未启用 SACD。§4.4 中的 schema-valid 率主要反映 role-safe JSON 合约、schema 复制提示与解析器校验共同形成的输出边界，而非语法约束解码带来的结果。

3.5 解析与诊断

解析器（generation/parser.py）先做 JSON 抽取（剥离 markdown 围栏、移除前后多余文本），再逐事件校验：事件类型是否属于 S 、角色是否属于 $\mathcal{R}_t$ 、取值形状是否合法，并分别累计 parse_failure、invalid_event_type、invalid_role 等诊断计数。这些计数在 §4 中作为输出鲁棒性证据报告。

3.6 规则记录消歧（主路径，no-LRD）

同类多记录的消歧使用规则 planner（实现见 postprocess/rule_planner.py），也是本文主结果所用路径。每个目标事件类型预定义一组 anchor 角色，例如“质押”主要依赖质押方、质押物、质押股份数量与事件时间确定记录边界。planner 依次执行：精确去重、空目标事件丢弃、多 anchor 值的保守拆分、anchor 与 arguments 兼容时的保守合并、以及同 anchor 签名下的近重

复保留更完整记录。其要点是只有 anchor 签名相同且角色兼容的记录才允许合并，避免把高相似但互斥的真实记录误并为一。

本文亦实现了一个 learned 记录消歧 (LRD) 原型 (postprocess/lrd_planner.py, 含 safe anchor 修复, 使学习到的 cluster 在合并时继承 anchor/role 兼容边界)。但 LRD 仅作为诊断与未来工作; 本文主表与全部对比均为 no-LRD 规则路径, 不报告 LRD 的 test 结论。

3.7 Canonical JSONL 与三轨评测口径

预测导出为 canonical JSONL (evaluation/export.py), 再转评测器格式 (evaluation/evaluator_adapter.py) 后, 在三个独立轨道上进行评测。主表只用 Legacy-FS (Doc2EDAG-style native fixed-slot): 在同文档、同事件类型内匹配记录, 并在固定 schema 角色槽位上统计 TP 、 FP 、 FN 。其中, TP 表示预测记录与 gold 记录匹配后, 某一固定角色槽位的文本取值完全匹配; 未匹配的预测槽位计为 FP , 未覆盖的 gold 槽位计为 FN 。公式为

$$P = \frac{TP}{TP + FP}, \quad R = \frac{TP}{TP + FN}, \quad F1 = \frac{2PR}{P + R}.$$

该口径用于与 EPAL/SEELE 公开 fixed-slot 表格对齐。指标族边界见表 1: Unified-Strict 回答 canonical JSONL 的严格文本匹配问题 (并提供 exact-record 诊断), DocFEE-Official 仅服务 DocFEE official-style 轨道, 二者均不与主表混算。

表 1: 评测指标族边界。三族回答不同问题, 不可压成单一综合数。

指标族	本文位置	边界说明
Legacy-FS	主表	Doc2EDAG-style native fixed-slot 口径; 与 EPAL/SEELE 公开 fixed-slot 表格对齐。
Unified-Strict	附录诊断	canonical JSONL 严格文本匹配口径, 并提供 exact-record 诊断。
DocFEE-Official	不用于本文主表	DocFEE official-style 专用轨道; 本文两个主数据集不报告该指标。

4 实验

4.1 数据集、基线与运行配置

本文使用两个中文金融文档级事件抽取数据集。ChFinAnn-Doc2EDAG 取其 dev (full-dev, 3204 篇) 作为本轮 ChFinAnn 结果来源; DuEE-Fin 使用内部构造的 labeled test (1171 篇) 作为主结果来源。¹ 公开基线采用 EPAL 论文 Table 1 / Appendix Table 4–5 与 SEELE 论文 Table 2–3 的报告值; 对原文未报告的 P/R 或单/多事件细分保留缺失值, 不做插补。

可比性声明 (重要)。 EPAL/SEELE 的公开数字是在其各自 test split 上报告的, 而 SARGE 在 ChFinAnn 为 dev、在 DuEE-Fin 为内部 labeled test。因此本文所有数值比较均应理解为公开表格口径下的参考点比较, 而非同一隐藏测试集或线上 leaderboard 上的 head-to-head。运行配置

¹服务器内部目录名保留了历史构造标签, 其中 dev500 不表示 labeled test 的文档数; 本文另将 500 篇开发集消融称为 DuEE-Fin dev subset。

见表 2：两个数据集的主结果分别来自 vLLM BF16 merged 与 HF 4-bit NF4 + LoRA 两个推理后端。由于完整运行可用性不同，当前主结果后端不对称；后端差异会影响数值解释，因此在 §4.4 中单独量化，并在 §4.5 中作为限制报告。两结果均来自服务器 /data/TJK/DEE/SARGE/ 的完成运行，seed 13。

表 2: SARGE 主结果运行配置。当前完整运行证据中，ChFinAnn 与 DuEE-Fin 的主结果来自不同推理后端；同 split 后端差异见表 7。

数据集	split	文档数	后端	模型	权重	解码	seed	F1
ChFinAnn	dev (full-dev)	3204	vLLM 0.8.5	Qwen3-4B + LoRA ep2 merged	BF16 merged	k=1 greedy	13	85.5
DuEE-Fin	labeled test	1171	HF Transformers 5.4.0	Qwen3-4B + LoRA ep2 adapter	4-bit NF4 + bf16 compute	k=1 greedy	13	78.0

4.2 主结果

表 3: 公开 fixed-slot 基线与 SARGE 主结果（单位：%）。EPAL/SEELE 为论文公开 *test* split；SARGE split 见来源列。对比仅作公开表格参考点，非同测试集 head-to-head。

数据集	方法	来源/split	P	R	F1	F1(S.)	F1(M.)
ChFinAnn	Doc2EDAG	EPAL Table 1	82.7	75.2	78.8	83.9	67.3
ChFinAnn	DE-PPN	EPAL Table 1	83.7	76.4	79.9	85.9	68.4
ChFinAnn	PTPCG	EPAL Table 1	83.7	75.4	79.4	88.2	—
ChFinAnn	GIT	EPAL Table 1	82.3	78.4	80.3	87.6	72.3
ChFinAnn	ReDEE	EPAL Table 1	83.9	79.9	81.9	88.7	74.1
ChFinAnn	ProCNet	EPAL Table 1	83.6	78.1	80.8	87.5	73.5
ChFinAnn	EPAL	EPAL Table 1	83.1	83.5	83.4	89.7	76.6
ChFinAnn	SEELE	SEELE Table 2	—	—	85.1	—	—
ChFinAnn	SARGE	本项目 (dev/full-dev)	83.5	87.6	85.5	88.3	83.1
DuEE-Fin	Doc2EDAG	EPAL Table 1	67.1	60.1	63.4	69.1	58.7
DuEE-Fin	DE-PPN	EPAL Table 1	69.0	33.5	45.1	54.2	21.8
DuEE-Fin	PTPCG	EPAL Table 1	71.0	61.7	66.0	—	—
DuEE-Fin	GIT	EPAL Table 1	69.8	65.9	67.8	73.7	63.8
DuEE-Fin	ReDEE	EPAL Table 1	77.0	72.0	74.4	78.9	70.6
DuEE-Fin	ProCNet	EPAL Table 1	79.3	71.4	75.1	80.1	71.0
DuEE-Fin	EPAL	EPAL Table 1	77.3	75.5	76.4	81.2	72.7
DuEE-Fin	SEELE	SEELE Table 3	—	—	80.8	—	—
DuEE-Fin	SARGE	本项目 (labeled test, 1171 docs)	76.6	79.3	78.0	79.3	77.5

表 3 给出公开 fixed-slot 口径下的总体结果。在公开表格参考点意义上，SARGE 的 ChFinAnn 数值为 85.5，与 SEELE 公开值处于同一水平，并数值高于 EPAL 公开值；DuEE-Fin 数值为 78.0，数值高于 EPAL 公开值但低于 SEELE 公开值。由于 split 口径不一致，这些结果不构成隐藏测试集或 leaderboard 结论。

从数据集差异看，ChFinAnn 的 schema 边界与角色集合相对稳定，surface memory 与 role-safe 合约更易把候选证据压进可控空间；DuEE-Fin 角色集合更大、同类事件与数值参数更密集，因此 SARGE 在公开参考点上接近但仍未达到 SEELE 的 DuEE-Fin 数值。




图 2: SARGE 与公开 fixed-slot 基线主结果 (坐标轴自 0 起, 不截断)。SARGE 的 ChFinAnn 为 dev(full-dev)、DuEE-Fin 为 labeled test; 对比仅作公开表格参考点。

4.3 分事件类型分析

表 4: ChFinAnn 分事件类型 fixed-slot F1 (dev/full-dev, 单位: %)

代码	事件类型	EPAL	SEELE	SARGE	Δ EPAL	Δ SEELE
EF	EquityFreeze	74.8	78.8	87.3	12.5	8.5
ER	EquityRepurchase	93.4	92.0	90.3	-3.1	-1.7
EU	EquityUnderweight	76.3	77.7	82.5	6.2	4.8
EO	EquityOverweight	77.3	82.4	84.6	7.3	2.2
EP	EquityPledge	81.5	83.1	84.6	3.1	1.5

表 4 显示, 在公开表格参考点意义上, SARGE 在 ChFinAnn 的 EquityFreeze、EquityUnderweight、EquityOverweight、EquityPledge 上数值高于 EPAL 与 SEELE 公开值; EquityRepurchase 为 90.3, 低于 EPAL (93.4) 与 SEELE (92.0) 但仍处高位。该结果与方法设计相符: 当 schema 边界清楚、角色取值在文本中显式出现时, surface memory 与 role-safe 合约能有效降低生成空间。

表 5 显示 DuEE-Fin 分类型结果更不均衡: SARGE 在企业收购、中标等类别上接近 EPAL/SEELE 的公开值, 在企业破产、被约谈等类别上数值高于 SEELE 公开值; 但在公司上市、股东增持、企业融资、股份回购、亏损、高管变动等类别上仍低于 SEELE。尤其在质押、解除质押上, SARGE 数值高于 EPAL 公开值, 但与 SEELE 仍有明显差距。这提示 DuEE-Fin 的难点不仅在 schema 约束, 更在复杂角色组合、数值密集证据与同文多事件消歧。




图 3: ChFinAnn (dev) 与 DuEE-Fin (labeled test) 分事件类型 fixed-slot F1 对比。图中数值为公开表格参考点对照。

表 5: DuEE-Fin labeled test 分事件类型 fixed-slot F1 (单位: %)

代码	事件类型	EPAL	SEELE	SARGE	Δ EPAL	Δ SEELE
CL	公司上市	59.1	66.5	64.1	5.0	-2.4
SR	股东减持	74.5	76.7	76.7	2.2	0.0
EO	股东增持	57.5	75.5	71.5	14.0	-4.0
EA	企业收购	68.3	72.1	72.2	3.9	0.1
FI	企业融资	76.1	79.1	77.6	1.5	-1.5
ER	股份回购	91.3	94.8	91.0	-0.3	-3.8
EP	质押	78.2	85.3	79.5	1.3	-5.8
CP	解除质押	76.8	84.8	79.2	2.4	-5.6
GB	企业破产	69.3	62.0	67.4	-1.9	5.4
EL	亏损	86.1	86.2	83.9	-2.2	-2.3
BG	被约谈	71.1	58.0	70.3	-0.8	12.3
BI	中标	76.3	76.6	76.9	0.6	0.3
SC	高管变动	61.2	64.8	63.4	2.2	-1.4

4.4 消融与分析

本节全部基于已完成的真实运行 (来自 docs/exp_result.md 与服务器 eval), 不引入任何新训练或推理。

监督微调增益。 表 6 与图 4 给出 no-SFT 基座与 LoRA-SFT 在同 split、同后端下的对比。ChFinAnn (vLLM, full-dev) 由 18.6 提升到 85.5 (+66.9pp); DuEE-Fin dev subset (500 docs) 在 HF 后端由 3.8 提升到 76.7 (+72.8pp)、在 vLLM 后端由 11.2 提升到 72.8 (+61.5pp)。这说明任务的难度主要由领域适配承担, 受控生成框架在微调后才能稳定落到 fixed-slot 评测。

表 6: 监督微调 (SFT) 增益。同一 split、同一后端下, no-SFT 基座与 LoRA-SFT 的 fixed-slot F1 对比 (单位: %)。

数据集	split	后端	no-SFT	SFT	Δ
ChFinAnn	dev/full-dev (3204 docs)	vLLM 0.8.5 BF16	18.6	85.5	66.9
DuEE-Fin	dev subset (500 docs)	HF Transformers 4-bit NF4 + LoRA	3.8	76.7	72.8
DuEE-Fin	dev subset (500 docs)	vLLM 0.8.5 BF16 merged	11.2	72.8	61.5

推理后端。 表 7 在同 split、同 $k = 1$ greedy 下对比 HF 4-bit NF4 + LoRA 与 vLLM BF16 merged。DuEE-Fin dev subset 上 HF 数值高于 vLLM (76.7 vs 72.8, $\Delta_{\text{vLLM-HF}} = -3.9\text{pp}$), ChFinAnn dev subset 上二者接近 (84.4 vs 84.2, $\Delta_{\text{vLLM-HF}} = -0.2\text{pp}$)。该差异已验证非 balanced_json_stopping 截断所致, 说明推理后端会影响结果解释, 因此当前跨数据集主结果不能完全归因于模型结构本身。

解码策略。 表 8 与图 5 (右) 显示, $k = 4$ 采样在两数据集上整体不优于 $k = 1$ greedy: ChFinAnn full-dev 上 $T=0.7$ 较 greedy 下降 1.2pp; DuEE-Fin dev subset 上仅 $T=0.3$ 略高 (73.9 vs 72.8),




图 4: 监督微调增益 (同 split / 同后端)。

表 7: 推理后端对比 (同 split、同 k=1 greedy)。HF 4-bit NF4 + LoRA 与 vLLM BF16 merged 的 fixed-slot F1 (单位: %); 负的 Δ 表示 HF 数值高于 vLLM。

数据集	split	HF 4-bit NF4	vLLM BF16	$\Delta = \text{vLLM} - \text{HF}$
DuEE-Fin	dev subset (500 docs)	76.7	72.8	-3.9
ChFinAnn	dev subset (500 docs)	84.4	84.2	-0.2

$T=0.5/0.7$ 均不及 greedy。金融事件抽取对实体、日期、金额和股数边界高度敏感，较高随机性容易破坏精确文本边界，因此主结果采用确定性 greedy。

表 8: 解码策略消融 (vLLM BF16)。greedy(k=1) 与 sampling(k=4, top_p=0.95) 在不同温度下的 fixed-slot F1 (单位: %); - 表示未运行, 而非不适用。

数据集	split	k=1 greedy	k=4 T=0.3	k=4 T=0.5	k=4 T=0.7
DuEE-Fin	dev subset (500 docs)	72.8	73.9	72.7	72.3
ChFinAnn	dev/full-dev (3204 docs)	85.5	-	-	84.3

输出鲁棒性与 exact-record。 表 9 显示 role-safe 合约的直接收益：ChFinAnn dev 与 DuEE-Fin labeled test 上 schema-valid 率均为 1.0，解析失败、非法事件类型、非法角色计数均为 0。在 Unified-Strict 口径下，DuEE-Fin labeled test 的 exact-record F1 为 42.9，高于 ProcNet 同口径 seed42 参考的 22.7。该对比衡量的是**整条记录**的严格正确率，是 fixed-slot 之外对多记录消歧质量的补充证据。

4.5 限制

本文有意保持窄口径：

- **split 可比性**：ChFinAnn 主结果在 dev、DuEE-Fin 在内部 labeled test，与 EPAL/SEELE




图 5: 左：推理后端对比（同 split, k=1 greedy）；右：解码策略消融（vLLM BF16）。纵轴为局部范围，用于展示相邻设置差异。

表 9: 输出鲁棒性与 exact-record 诊断 (Unified-Strict 口径)。schema-valid rate 为 schema 合法预测占比；exact-record F1 = $2 \cdot \text{record_exact_match} / \text{validated_record}$ 。ProcNet 为同口径 seed42 参考。

指标	ChFinAnn dev	DuEE-Fin labeled test
schema-valid rate	1.0	1.0
parse failures	0.0	0.0
invalid event types	0.0	0.0
invalid roles	0.0	0.0
SARGE exact-record F1	—	42.9
ProcNet exact-record F1 (seed42)	—	22.7

的 test split 不同；与公开表格的比较仅为参考点。

- **后端不对称**：两数据集主结果使用不同推理后端；当前完整运行证据中，ChFinAnn full-dev 对应 vLLM，DuEE-Fin labeled test 对应 HF 4-bit NF4。后端差异会影响数值解释，同后端 cross-check 需在后续补齐。
- **单种子**：仅 seed 13，不报告 mean±std 与统计显著性。
- **记录消歧**：主结果为 no-LRD 规则路径；learned LRD 仅诊断，不报告 test 结论。
- **无隐藏测试集/leaderboard 结论**：仓库无对应完整证据。

这些限制界定了当前证据能支持的表述范围。与此同时，所有数值均绑定到 run root、eval 哈希与本地快照，并由资产生成脚本的完整性断言锁定，便于复核并降低编辑漂移风险。

5 结论

本文提出 SARGE，一个面向中文金融文档级事件抽取的 Schema-Aware Role-Grounded Extractor：以规则候选作 surface memory、以 role-safe JSON 合约约束受控生成、以 anchor 规则消歧处理同类多记录，并以严格分离的指标族报告。在公开 fixed-slot 表格参考点意义上，SARGE 在 ChFinAnn full-dev 取得 85.5 F1、在 DuEE-Fin labeled test 取得 78.0 F1，并在两数据集上实现 1.0 的 schema-valid 率与零解析失败。后续工作包括补齐同后端 cross-check 与多种子结果、以及完成 learned 记录消歧的 test 评测。